DecisionCoach AI

Proyecto Final - Sistema RAG para Toma de Decisiones, Comunicación e IA

Integrantes:
- Rios Hermoza, Martin
- Validivia Alfaro, Jose
- Yepez Anglas, Miguel Angel

Proyecto Final · IA Generativa – 2026-I

El Problema

❓ Información dispersa

Los documentos importantes están repartidos en archivos, PDFs y fuentes distintas.

🤖 Respuestas sin fundamento

Los modelos de IA generan respuestas plausibles pero a veces inventadas (alucinaciones).

🔍 Búsqueda ineficiente

Encontrar la información correcta en el momento adecuado toma demasiado tiempo.

📉 Decisiones sin contexto

Sin acceso rápido a evidencia, las decisiones importantes pierden calidad.

¿Qué es DecisionCoach AI?

Un asistente inteligente que:

- Lee y comprende tus documentos reales
- Recupera exactamente lo que necesitas
- Genera respuestas fundamentadas en evidencia
- Cita la fuente de cada afirmación
- Detecta y evita alucinaciones automáticamente

Casos de uso:

📋 Toma de decisiones

💬 Comunicación estratégica

🧠 Preguntas sobre IA

📚 Consulta de documentos

Arquitectura del Sistema (RAG)

Documentos
PDFs, TXT, Wikipedia

Chunking
Fragmentos con overlap

Embeddings
Vectores numéricos

FAISS HNSW
Índice vectorial

Retrieval
Top-K fragmentos

Reranker
Cross-encoder

Query Rewrite
Mejora la pregunta

LLM
Genera la respuesta

Evaluation
Citation x Sentence
Hallucination Guard
Grounding Score
Bleu Rouge

Cross-Encoder

Reordena resultados por relevancia real

Bleu Rouge

Búsqueda rápida en millones de vectores

Grounding Score

Mide qué tan basada está la respuesta en el contexto

Hallucination Guard

Verifica que la respuesta tenga respaldo en el texto

Citation per Sentence

Cada oración indica su fuente exacta

Dataset + Chunking

📂 Dataset Externo

- Se cargan documentos desde múltiples fuentes web (IA, psicología, negocio y comunicación)
- Cada documento incluye metadata:
  - categoría
  - fuente
  - URL
- Se dividen en fragmentos (chunks)
- Se usa overlap para no perder contexto

✂️ Chunking con Overlap

¿Por qué fragmentar?

Los modelos solo procesan texto corto a la vez.
Dividimos el documento en trozos manejables.

¿Qué es el overlap?

Ejemplo: fragmentos de 512 tokens con 64 de overlap.
Así no se pierde contexto en los bordes.

FAISS HNSW + Reranker

📁 FAISS + HNSW

¿Qué es FAISS?

Librería de Facebook para búsqueda ultrarrápida entre millones de vectores.

¿Qué es HNSW?

"Hierarchical Navigable Small World": grafo de capas que permite navegar desde lo general hasta lo específico para encontrar los vecinos más cercanos en ms.

Ventaja clave:

No revisa cada fragmento uno a uno. Salta inteligentemente entre nodos → mucho más rápido.

🏆 Reranker (Cross-Encoder)

¿Por qué reranquear?

FAISS devuelve los fragmentos más cercanos matemáticamente, pero no siempre el más relevante semánticamente.

¿Cómo funciona?

El cross-encoder analiza la pregunta y cada fragmento JUNTOS para evaluar la relevancia real, no solo la similitud de vectores.

Resultado:

Los fragmentos se reordenan → el LLM recibe el contexto de mayor calidad.

Pregunta→ FAISS + BM25→ varios resultados → Reranker → mejores resultados

Alucinaciones, Grounding y Citaciones

🚨 Hallucination Guard

- Problema: el modelo puede inventar datos.
- Solución: cada respuesta es comparada contra el contexto recuperado.
- Si la respuesta no está respaldada → se descarta o se marca.

📊 Grounding Score (0–1)

- Se calcula qué tan fundamentada está la respuesta.
- Score 1.0 = completamente respaldada por el texto.
- Score 0.0 = la respuesta no tiene evidencia en los docs.

📌 Citation per Sentence

- Cada oración de la respuesta lleva su fuente.
- Ejemplo: "La IA reduce costos [Fuente: doc3, p.12]"
- Aumenta confianza y permite verificar manualmente.

Demo en Vivo

```
==================================================
🔍 DEBUG RETRIEVAL
Query: what is emotional intelligence?
Retrieved docs: 25
Reranked docs: 2
Top docs: 1
==================================================

============================================================
🧠 QUESTION: What is emotional intelligence?
============================================================

📌 Answer:
Emotional intelligence is the ability to recognize, understand, and manage one's own emotions, as well as the emotions of others [emotional_intelligence]

📊 Evaluation:
• Hallucination: ✅ Respuesta confiable
• Hallucination Score: 0.83
• Grounding Score: 1.19

📚 Sources:

[1] EMOTIONAL_INTELLIGENCE
🔗 https://www.psychologytoday.com/us/basics/emotional-intelligence
```

Demo en Vivo

```
==================================================
🔍 DEBUG RETRIEVAL
Query: what is rag?
Retrieved docs: 25
Reranked docs: 2
Top docs: 1
==================================================

============================================================
🧠 QUESTION: What iss RAG?
============================================================

📌 Answer:
Rag is a retrieval-augmented generation technique that leverages large language models (LLMs) to retrieve and incorporate external data sources into its resp
onses [rag]. In this approach, LLMs first reference a predefined set of documents, which can be corporate literature, industry reports, or other relevant sou
rces [rag]. Once the LLM has accessed these documents, it can utilize them to generate responses to user queries [rag]. By incorporating external data, RAG a
llows LLMs to leverage domain-specific knowledge and up-to-date information that might not have been present in their training data [rag]

📊 Evaluation:
• Hallucination: ✅ Respuesta confiable
• Hallucination Score: 0.50
• Grounding Score: 0.71

📚 Sources:

[1] RAG
🔗 https://en.wikipedia.org/wiki/Retrieval-augmented_generation
```

Evaluación Automática

BLEU Score

Mide cuántas palabras de la respuesta generada coinciden con la respuesta esperada.

Ejemplo: si la respuesta ideal tiene 10 palabras y el modelo acierta 8 → BLEU ≈ 0.8

Útil para preguntas con respuesta única

ROUGE Score

Mide la superposición de n-gramas (secuencias de palabras) entre la respuesta y la referencia.

ROUGE-1: palabras individuales
ROUGE-2: pares de palabras

Mejor para respuestas largas y resúmenes

Grounding Score

Mide qué tan respaldada está cada oración de la respuesta en los documentos recuperados.

Calcula similitud semántica entre respuesta y contexto.

Específico para sistemas RAG

Resultados de Pruebas

7 preguntas reales · 3 temas distintos · 0 alucinaciones detectadas

Pregunta	Tema	Halluc.	H. Score	Ground.	Estado
What is RAG?	RAG	✅ Confiable	0.50	0.71	✅ OK
How does RAG improve LLM?	RAG	✅ Confiable	0.53	0.75	✅ OK
Role of embeddings in RAG?	RAG	✅ Confiable	0.43	0.61	✅ OK
What are mental models?	Mental Models	✅ Confiable	0.43	0.62	✅ OK
Why are mental models imp.?	Mental Models	✅ Confiable	0.45	0.65	✅ OK
What is emotional intelligence?	Emociones	✅ Confiable	0.83	1.19*	✅ OK
What is leadership?	Liderazgo	✅ Confiable	0.50	0.71	✅ OK

0.75 Grounding Promedio
+1 outlier

0.52 Halluci. Score Avg
rango 0.43–0.83

7 / 7 Respuestas Confiables
100%

4 Temas Cubiertos
RAG, MM, EI, Liderazgo

** Grounding >1.0 indica alta similitud semántica en respuesta corta y directa*

Resultados

✅ Calidad de respuestas

- Respuestas basadas en contexto real
- Uso correcto de fuentes (citation per sentence)
- Información relevante y coherente

✅ Robustez del sistema

- Manejo de errores en queries
  - (ej: “What iss RAG?” → corregido)
- Respuestas consistentes en múltiples dominios

✅ Recuperación de información

- ~25 documentos recuperados inicialmente
- 2 documentos tras reranking
- 1 documento final usado como contexto

Conclusiones

- ✅ **Pipeline RAG completo —** Desde documentos reales hasta respuesta fundamentada.
- ✅ **Búsqueda eficiente —** FAISS HNSW permite escalar a millones de fragmentos.
- ✅ **Calidad de recuperación —** El reranker mejora la relevancia del contexto entregado al LLM.
- ✅ **Sin alucinaciones —** Grounding score + citation per sentence garantizan veracidad.
- ✅ **Medición objetiva —** BLEU/ROUGE permiten evaluar la calidad de forma automática.